

سوال نمبر : آیا جان بدد کا سر loss دیکھا ہے یا نہیں

کون سا loss ایسا ہے؟

↓

Ex: { MAE } mye }

$$\text{Error} = \frac{y_{\text{true}} - y_{\text{predicted}}}{x}$$

mAE / mse

$$\left\{ \begin{array}{l} \text{mAE} = \frac{1}{n} \sum |y_t - y_p| \\ \text{mse} = \frac{1}{n} \sum (y_t - y_p)^2 \end{array} \right.$$

①

$$y_t \geq y_p \rightarrow |y_t - y_p| = (y_t - y_p)$$

$$\text{① } \text{mAE} = \frac{1}{n} \sum (y_t - y_p) \leadsto \text{mse} = n \left(\frac{1}{n} \right) \left(\frac{1}{n} \right) \sum (y_t - y_p)(y_t - y_p)$$

$$\text{mse} = n (\text{mAE})^2 \rightarrow$$

$$\boxed{mse = n (mae)^2} \quad \alpha$$

$$\frac{2vv'}{}$$

$$\frac{\partial}{\partial w} v^2 = 2v \frac{\partial v}{\partial w}$$


$$\frac{\partial mse}{\partial w} = n \frac{\partial}{\partial w} (mae)^2 = 2n (mae) \frac{\partial mae}{\partial w}$$

y + \gamma y_p

$$\frac{\partial mse}{\partial w} = 2n (mae) \frac{\partial mae}{\partial u}$$

$y_A > y_P$

loss (mse, mae)



②

$$\underline{y_+ < \underline{y_p}}$$

$$\underline{y_+ - y_p < 0}$$

$$mse = \frac{1}{n} \sum (\underline{y_+ - y_p})^2$$

- x -

$$MAE = \frac{1}{n} \sum |\underline{y_+ - y_p}|$$

$$[y_+ < y_p] \approx [y_+ > y_p]$$

$$\underline{y_+ < y_p}$$


$$\left\{ \begin{array}{l} mse = \frac{1}{n} \sum \underbrace{(y_+ - y_p)^2}_{\rightarrow} \\ mae = \frac{1}{n} \sum |y_+ - y_p| \end{array} \right.$$

$$\left\{ \begin{array}{l} (y_+ - y_p)^2 = (y_p - y_+)^2 \\ |y_+ - y_p| = |y_p - y_+| \end{array} \right.$$


$$[y_+ < y_p] \approx [y_+ < y_p]$$


③

$$\underline{y_t = y_p}$$



$$\text{mse} \rightarrow \frac{1}{n} \sum (\underline{y_t} - \underline{y_p})^2 = 0$$

$$\text{MAE} = \frac{1}{n} \sum |y_t - y_p|^2 = 0$$






نحوه جلوگیری از بیش برآزش و کم برآزش

{Avoiding Under-fitting & Over-fitting }




✗

Underfit





✓

Optimal




Overfit





less



تعداد صفه w_2 ست	وزن ست w_1	نتیجه ست
<u>10,000</u>	2 5 80	200
α (100,000)		350
1,000,000		1500
x_2	x_1	y

اگر سال شونده!

وزن مقدار هر

0-1 0-1

$$y = w_1 (x_1) + w_2 x_2$$

$$y = w_1 + w_2 (10,000)$$


$$200 = w_1 + \frac{1}{50} (10,000)$$

همه نتایج ستدهای غیر منفی را در جدول



۱. Normalization (نرمال سازی)

تبدیل مقادیر ویژگی ها به بازه ای ثابت (معمولاً بین 0 و 1)



$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

train

Area	price
200	
300	
100	
50	


$$\alpha = \frac{x - x_{min}}{x_{max} - x_{min}}$$

*

$$x_{min} = 50$$

$$x_{max} = 300$$

دائرة



$\frac{mi-}{-}$ $\frac{max}{-}$
 $-$ $-$

جلوگیری از Overfitting و Underfitting : نرمال کردن

• نرمال سازی باعث می شود همه ویژگی ها در مقیاس یکسان باشند.

- فقط برای داده های پیوسته مناسب است.
- روی داده های گسسته (مثل جنسیت ۰ یا ۱) نباید انجام شود.
- در حضور داده های پرت (outliers) ممکن است دچار انحراف شود.

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \times (max_{range} - min_{range}) + min_{range}$$

$$X = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (2)$$

Handwritten annotations for the first formula:
 - x_{min} : Minimum values of features
 - x_{max} : Maximum values of features
 - max_{range} : Maximum target range
 - min_{range} : Minimum target range



۲. Standardization (استاندارد سازی)

- برای داده‌های پیوسته مناسب است.
- روی داده‌های گسسته یا باینری (مثل ۰/۱ یا دسته‌ای) نباید استفاده شود.
- در برابر داده‌های پرت نسبت به نرمال سازی مقاوم تر است اما همچنان حساس است!

$$z = \frac{x - \mu}{\sigma}$$

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

$$\mu = \frac{1}{N} \sum_{i=1}^N (x_i)$$




normal distribution

توزیع گاوسی

رنگی /


Sum



Regularization

$\propto$ feature engineering

لش دنیج!



mse

بار بار

loss

w_1	w_2	
x_1	x_2	y

هدف شود!

w_1 و w_2 کمینه کردند

مقدار وزن کم کردیم

مقدار وزن کم کردیم



۲. Regularization (تنظیم مدل)

- ایده‌ی اصلی: مجازات کردن وزن‌های بزرگ.

نوع ۱

L1 Regularization (Lasso)





لیپ پارامتر ← هزینه، منعزل، نوسان دهنده، لقیق
می کند


$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |w_j|$$


لای

Penalty Term



x_1	x_2	x_3	y
-------	-------	-------	-----


$$\lambda [|w_1| + |w_2| + |w_3|]$$



A hand-drawn diagram illustrating a linear model equation. At the top, two green ovals contain the labels w_1 and w_2 . Below these, the equation $x_1 + x_2 = y$ is written in green ink. A horizontal line is drawn across the equation, and a vertical line is drawn under the x_2 term. A green arrow points from the w_1 oval to the x_1 term, and another green arrow points from the w_2 oval to the x_2 term.

Case:

$GD(m, g)$



جس سے من تقنیہ نہ آئے گا بازار کے بارے میں { ادارائی کمپنیاں دیکھ رہی ہیں۔


۱% تقنیہ لایا ہے بازار کے بارے میں وہ کہتے ہیں ، overfitting یہ سمجھا رہا ہے!



نوع 2

L_2 Reg. (Ridge)

α



جلوگیری از Overfitting و Underfitting : تنظیم مدل



$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p w_j^2$$


Penalty Term

← Ridge
خلفه هم کم کنه و بزرگ سخته و ریشه 2
Overfitting کنه!

$$\sum |w| \rightarrow |w_1| + |w_2| : \text{const}$$


$$\sum (w)^2 \rightarrow w_1^2 + w_2^2 = \text{const}$$

جلوگیری از Overfitting و Underfitting : تنظیم مدل



β_R Ridge Coefficients

● Ridge Constrained Region defining penalty term





β_L LASSO Coefficients

◆ LASSO constrained region defining penalty term

LASSO - Least Absolute Shrinkage and Selection Operator

β RSS (Least Square) Coefficients Contours of RSS





اگر داده‌ها پر از هم‌بستگی (correlation) بین ویژگی‌ها باشند،

Lasso ناپایدار است، ولی Ridge خوب عمل می‌کند.

اما Ridge همه ویژگی‌ها را نگه می‌دارد، در حالی که ما ممکن است

بخواهیم برخی حذف شوند.



نوع ۳

Elastic Net

ثبات و نرم بودن وزن ها (از L2) + انتخاب خودکار ویژگی ها (از L1)




$$J(w) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$

Handwritten annotations in red:

- mse (Mean Squared Error) above the first term.
- $\checkmark$ (checkmark) next to the first term.
- $Lasso$ above the second term.
- $ridge$ above the third term.

Elastic : Ridge + Case

جلوگیری از Overfitting و Underfitting : تنظیم مدل




our fitting $\rightarrow$!

وہ
۲۔ صحت
۳۔ ہا
صحت نہ رہے،
۴۔ ہم
آزاد کا سوا نہیں!



- Data Augmentation





- PCA (Feature Eng.)

Next Sessions

