



فرایند یادگیری ماشین

{ML Process}



The ML Process

Data engineer.

Data
CollectionData
CleaningEDA
(Exploratory
data analysis)Model
BuildingModel
Deploymentcard del. → car
stock pred. →

stock data.

✓ missing value

✓ outlier ✓

✓ normalization

✓ onehot encoding.

تفاوت دیتا

Train
Testcloud
server
boardmobile



آماده سازی داده

{Data Preparation}

{Data Collection + Data Cleaning + Data Transformation + Data Reduction}



دادهٔ خام معمولاً ناقص، نویزی و نامتعاذل است و نیاز به پاک‌سازی و تغییر دارد.



Data Preparation / why ?

Data Science

حدود ۵۰-۷۰٪ زمان پروژه های علم داده صرف
آماده سازی داده می شود.



پاکسازی داده ها

{Data Cleaning}



Data Cleaning / what?

duplicates

missing values

مدیریت مقادیر گم شده ، حذف موارد تکراری ،
داده های پرت و اصلاح مشکلات فرمت داده
ضروری است.

outlier

↓
string

۱۵۱۵

۱۲۵

۱۲۵

۲۱۵

→

→

۰

۱

[۰, ۱]

[۰, ۱]

- handle missing values
- remove duplicates
- remove outliers
- correct formatting issues



تبدیل داده ها

{Data Transformation}



Data Transformation / what?

داده‌های خود را استاندارد سازی و نرمال سازی کنید تا از سازگاری و کاهش نویز اطمینان حاصل شود. این مراحل می‌تواند شامل زیر باشد:

Scaling

Standardization

Normalization

One-Hot Encoding/Dummy



کاهش ابعاد

{Dimensionality Reduction}



Data Transformation / what?

ابعاد داده های خود را با انتخاب مرتبط ترین ویژگی ها کاهش دهید.

Principal Component Analysis (PCA)
Linear Discriminant Analysis (LDA)



پاکسازی داده ها

کشف داده های پرت

{Outliers Detection}



Outliers Finding!

'Age': [14, 17, 15, 15, 30, 16, 16, 16, 15, 17, 17, 18, 16]

در بالا شما سن دانش آموزان یک کلاس را می بینید، کدام یک داده ی پرت است؟



Outliers Finding!

۱) [14, 17, 15, 15, 30, 16, 16, 16, 15, 17, 17, 18, 16]

مرتب سازی داده ها

۲) [14, 15, 15, 15, 16, 16, 16, 16, 17, 17, 17, 18, 30]

نمایر

Outliers Finding!

۳۱ دانش آموز


[14, 15, 15, 15, 16, 16, 16, 16, 17, 17, 17, 18, 30]

6

6

عدد وسط (MEDIAN)
Q2
عدد وسط

Outliers Finding!



Q1=? 15
چارک اول

Q3=? 17
چارک سوم


عدد وسط (MEDIAN)

Q2

[Q1: 15 , چارک اول
Q2: 16 = میان : چارک دوم
Q3: 17 , چارک سوم]

Outliers Finding!

$IQR = Q3 - Q1$



$Q1 = 15$

$Q2 = 16 \rightarrow IQR = 17 - 15$
 $= 2$

$Q3 = 17$

$IQR = 2$

Interquartile Range


Data

Outliers Finding!


$Q_1: 15$
 $Q_2: 16$
 $Q_3: 17$
 $IQR: 2$

$$\left\{ \begin{array}{l} \text{min: } Q_1 - 1.5 \cdot IQR = 15 - 1.5(2) = 15 - 3 = 12 \rightarrow \text{min} \\ \text{max: } Q_3 + 1.5 \cdot IQR = 17 + 1.5(2) = 17 + 3 = 20 \rightarrow \text{max} \end{array} \right.$$

outliers $\left\{ \begin{array}{l} x < \text{min} \\ x > \text{max} \end{array} \right.$




Outliers Finding!





Logistic Reg



اگر مساله کلاسیفیکیشن بود این الگوریتم جواب میدهد؟

(سگ یا گربه)

0 1

Linear Regression

0.5

0.3

...

0.1


1000

100.5


اگر مساله کلاسیفیکیشن بود این الگوریتم جواب میدهد؟



بله، اما چطور؟



Logistic Reg!





۱. کمترین دریا به!

۲. تعبیرات را داشته باشد!

۳. شق نام داشته!

Sigmoid




$$\text{Sigmoid} = \frac{1}{1 + e^{-x}}$$

$$\text{Sigmoid} = \frac{1}{1 + e^{-x}}$$

$$x = \text{output of Reg.} = w_1x_1 + w_2x_2 + \dots$$

- × گنتے میں ہر اس
- × تعبیرات کا دلدادہ
- × سب سے بہتر ہے!




Sigmoid: $\longrightarrow$ Th: 5 $\begin{cases} \rightarrow 0,6 \rightarrow 1 \\ \rightarrow 0,3 \rightarrow 0 \end{cases}$ $\longleftarrow$ سۇل

توانىد Sigmoid ، صدىقى صىغىلىس ؟

binary classification $\longrightarrow$ Sigmoid

Binary
Classification



$.3$


$1 - .3 = .7$
Dog $\rightarrow$ cat

$.7 \rightarrow 1 + .7 = .3$
 $\downarrow$ True $\downarrow$ False

multi class classification?

اگر چند دسته داشته باشیم چطور؟

{ Dog
cat
tiger



سہاقتار یہ جس مجموعے کا! سو دیا!

Softmax($\underline{x}_i$):

$$\frac{e^{\underline{x}_i}}{\sum e^{\underline{x}_i}}$$

c1: 1000

c2: 800

c3: 900



$$\text{Softmax}(1) = \frac{e^{1000}}{e^{1000} + e^{800} + e^{900}} = \text{نتیجه: } \underline{\underline{0.7}}$$

$$\text{Softmax}(2) = \frac{e^{800}}{e^{1000} + e^{800} + e^{900}} \quad \text{نتیجه: } 0.2$$

$$\text{Softmax}(3) = \frac{e^{900}}{e^{1000} + e^{800} + e^{900}} \quad \text{نتیجه: } 0.1$$

loss func!

?

Sigmoid $\rightarrow$ Binary classification $\rightarrow$ Binary cross entropy

$$BCE = -\frac{1}{m} \left[\underset{\substack{\uparrow \text{actual} \\ \downarrow 1}}{y} \log \underset{\substack{\uparrow \text{predicted} \\ \downarrow .7}}{\hat{y}}} + (1-y) \log (1-\hat{y}) \right]$$

log. pg. $\left[\begin{array}{l} \rightarrow 1: \textcircled{.7} \\ \rightarrow 2: .3 \end{array} \right] \rightarrow -\frac{1}{2} \left[1 \log(.7) + \underbrace{(1-1)}_{=0} \log(1-.7) \right]$

$= -\frac{1}{2} \left[\log .7 \right] = -\frac{1}{2} \log .7$

The end