



تمرین ۷

۳۵۰۰ نمره



دیتاست Hotel booking demand datasets را دانلود کنید.

<https://github.com/mpolinowski/hotel-booking-dataset/tree/master/datasets>

این دیتاست حاوی اطلاعات رزرو برای یک هتل شهری و یک هتل تفریحی ست. اطلاعاتی مانند زمان رزرو، مدت اقامت، تعداد بزرگسالان، کودکان و یا نوزادان و اطلاعات دیگری را در خود جای داده است.

این دیتاست حاوی داده های واقعی می باشد که از مقاله ی زیر استخراج شده است:

<https://www.sciencedirect.com/science/article/pii/S2352340918315191>

نام ها، ایمیل ها، شماره تماس ها و شماره کارت های اعتباری موجود در داده ها غیر واقعی هستند و اطلاعات واقعی افراد نمی باشند. (این ستون ها را خودتان ایجاد کنید.)

این دیتاست را در نظر گرفته و قطعه کد مناسب برای موارد زیر بنویسید:

پیش پردازش: به صورت رندوم، دیتافریمی با ۹۰۰۰۰ ردیف یکتا با ستون های نام، فامیلی، ایمیل، شماره تماس، شماره کارت اعتباری یکتا و دیگر ستون های لازم ایجاد کنید. هر ردیف از این دیتافریم را به صورت رندوم به هر کدام از ردیف های دیتاست Hotel Booking جویین کنید. لازم نیست که نامها، ایمیلها و ... معنادار باشند. (۴۰۰)

۱. دیتاست را بخوانید. (۱۰۰)

۲. اطلاعات پایه ای دیتاست را بررسی کنید. (۱۰۰)

۳. این دیتاست چند سطر دارد؟ (۱۰۰)

۴. آیا داده گمشده (missing data) وجود دارد؟ اگر جواب مثبت است، کدام ستون ها بیشترین تعداد داده گمشده را دارند؟ (۲۰۰)

۵. ستون 'company' را از دیتافریم حذف کنید. (۲۰۰)

۶. بیشترین مسافران از کدام کشورها هستند؟ ۵ کشور نخست را مشخص کنید. (۳۰۰)

۷. نام فردی که بیشترین پرداختی (ADR(Average Daily Rate) را دارد را مشخص کنید. مبلغ آن چقدر است؟ (۳۰۰)

۸. میانگین کل ADR را مشخص کنید. (تا دو رقم اعشار) (۳۰۰)



۹. میانگین تعداد شب های اقامت را مشخص نمایید. (تا دو رقم اعشار) (۳۰۰)

۱۰. نام و آدرس ایمیل افرادی که ۵ تا special request داشته اند را مشخص نمایید. (۳۰۰)

۱۱. بیشترین فراوانی نام خانوادگی مربوط به چه نامهایی ست؟ (۵ فامیل پرتعداد را مشخص کنید). (۳۰۰)

۱۲. افرادی که همراه با بیشترین تعداد babies و children هتل رزرو کرده اند را مشخص کنید. (۳۰۰)

۱۳. کد تلفن مناطقی که بیشترین رزرو را داشته اند مشخص کنید. (سه کد پر تکرار) (۳۰۰)