



هدف تمرین : پیش‌بینی نوع شراب (Target) بر اساس ترکیبات شیمیایی با استفاده از K-Nearest Neighbors، به همراه Pipeline و Grid Search.

wine.csv

بخش ۱ — تحلیل و آماده‌سازی داده

1. فایل wine.csv را بارگذاری و ساختار داده را بررسی کنید. (تعداد سطر، ستون، نوع داده‌ها و بررسی داده‌های گم‌شده)
2. توزیع مقادیر ستون هدف Target را نمایش دهید. آیا کلاس‌ها متعادل هستند؟
3. میانگین و انحراف معیار مهم‌ترین ویژگی‌ها مثل Alcohol، Flavanoids و Color_Intensity را بررسی کنید. کدام ویژگی بیشترین تغییرپذیری را دارد؟
4. نمودارهای جفتی (Pairplot یا Scatter) بین چند ویژگی را رسم کنید تا تفکیک کلاس‌ها را مشاهده کنید.

بخش ۲ — آماده‌سازی برای مدل‌سازی

۱. داده را به دو بخش Train و Test تقسیم کنید (با `stratify=y` و نسبت 80/20). چرا استفاده از `stratify` در داده‌های چند کلاسه اهمیت دارد؟
۲. ویژگی‌ها را استانداردسازی کنید (`StandardScaler`). توضیح دهید چرا KNN بدون استانداردسازی نتایج اشتباه می‌دهد.
۳. مدل پایه‌ای KNN را با `k=5` و معیار فاصله `Euclidean` آموزش دهید. دقت آن را روی داده `Test` محاسبه کنید.

بخش ۳ — Grid Search و Pipeline

۱. یک Pipeline بسازید که شامل دو مرحله باشد:

- مرحله اول: `StandardScaler`
- مرحله دوم: `KNeighborsClassifier`

۲. با استفاده از `GridSearchCV`، مقادیر زیر را برای مدل بررسی کنید:

- `n_neighbors: [3, 5, 7, 9, 11]`
- `weights: ["uniform", "distance"]`
- `metric: ["euclidean", "manhattan"]`
- از `cv=5` و `scoring="accuracy"` استفاده کنید.

۳. بهترین ترکیب پارامترها را گزارش کنید (`_grid.best_params`).

- میانگین دقت ۵-تایی (`cross-validation accuracy`) را نیز بنویسید.

بخش ۴ — ارزیابی و تحلیل نتایج

۱. مدل بهینه را روی دادهٔ Test ارزیابی کنید:

- accuracy_score

- confusion_matrix

- classification_report

۲. ماتریس آشفتگی (CM) را رسم کنید.

- کلاس‌هایی که بیشترین اشتباه در پیش‌بینی را داشته‌اند مشخص کنید.

۳. رابطه بین مقدار k و دقت مدل را در نمودار رسم کنید.

- در چه مقدار k مدل دچار overfitting یا underfitting می‌شود؟

۴. تفاوت بین معیارهای فاصله Euclidean و Manhattan را در نتایج مدل توضیح دهید.

- در چه شرایطی استفاده از Manhattan بهتر است؟

۵. خروجی مدل را روی چند نمونهٔ جدید از داده (که در آموزش استفاده نشده‌اند) تست کنید.

بخش ۵ — تحلیل نهایی و پیشنهادها

۱. کدام ویژگی‌ها بیشترین نقش را در تفکیک نوع شراب دارند؟ با استفاده از تحلیل همبستگی (correlation matrix) پاسخ دهید.

۲. اگر بخواهید مدل سریع‌تر ولی با دقت مشابه بسازید، چه روشی پیشنهاد می‌دهید؟
(مثلاً کاهش بعد با PCA (در جلسات بعدی یادش می‌گیریم) یا حذف ویژگی‌های کم‌اهمیت)

۳. عملکرد KNN را با یک مدل ساده دیگر (مثل Log. Reg.) مقایسه کنید.

۴. محدودیت اصلی الگوریتم KNN چیست؟ در پروژه‌های بزرگ‌تر چگونه می‌توان آن را بهینه کرد؟

۵. به صورت خلاصه بنویسید:

- نقاط قوت KNN
- نقاط ضعف KNN
- شرایطی که استفاده از آن مناسب‌تر است



ارادتمند شما / جی پی تی

با نظارت امین ;)